Big Data e Business Intelligence

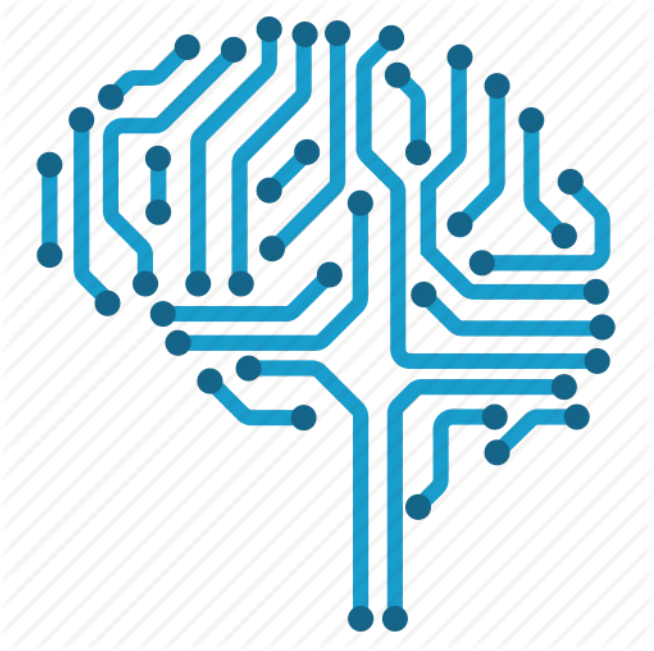

Machine Learning

Giulio Angiani - UniPr

Machine Learning - primi passi

Machine Learning

Cos'è ML

- Capacità di un algoritmo di **prendere decisioni** sulla base di una knowledge-base (base di conoscenza) e di **apprendere** nuove informazioni sulla base dell'esperienza (decisioni prese precedentemente)

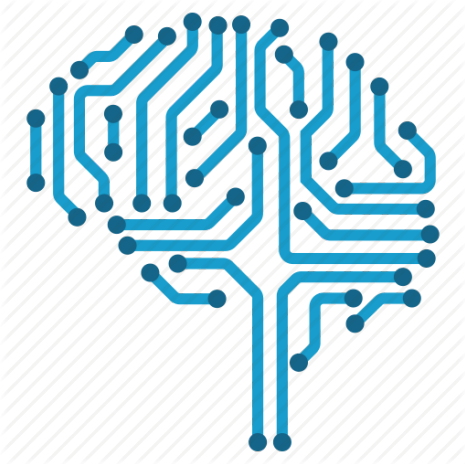

3 tipologie fondamentali

- Supervised learning (apprendimento supervisionato)
- UnSupervised learning (apprendimento non supervisionato)
- Semi-Supervised learning (apprendimento semi-supervisionato)

Machine Learning

*L'**apprendimento supervisionato** è una tecnica di apprendimento automatico che mira a istruire un sistema informatico in modo da consentirgli di elaborare automaticamente previsioni sui valori di uscita di un sistema rispetto ad un input sulla base di una serie di esempi ideali, costituiti da coppie di input e di output, che vengono inizialmente forniti*[1]

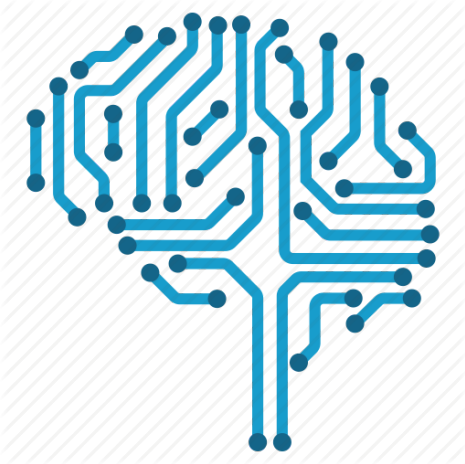

- insieme di dati di addestramento (**training set**)
- insieme di dati di confronto (**test set**)
- **labeling** (annotazione) e **classi**

traning set contiene informazioni labeled per permettere all'algoritmo di trovare il modo **migliore** per indovinare più casi possibile.
il labeling permette all'algoritmo di imparare a **discernere** un esempio dagli altri

test set contiene informazioni del tutto **simili** per poter calcolare l'**accuratezza** dell'algoritmo addestrato

Machine Learning

Un esempio di **apprendimento supervisionato**

- dati forniti con labels => il modello può prevedere/assegnare una classe

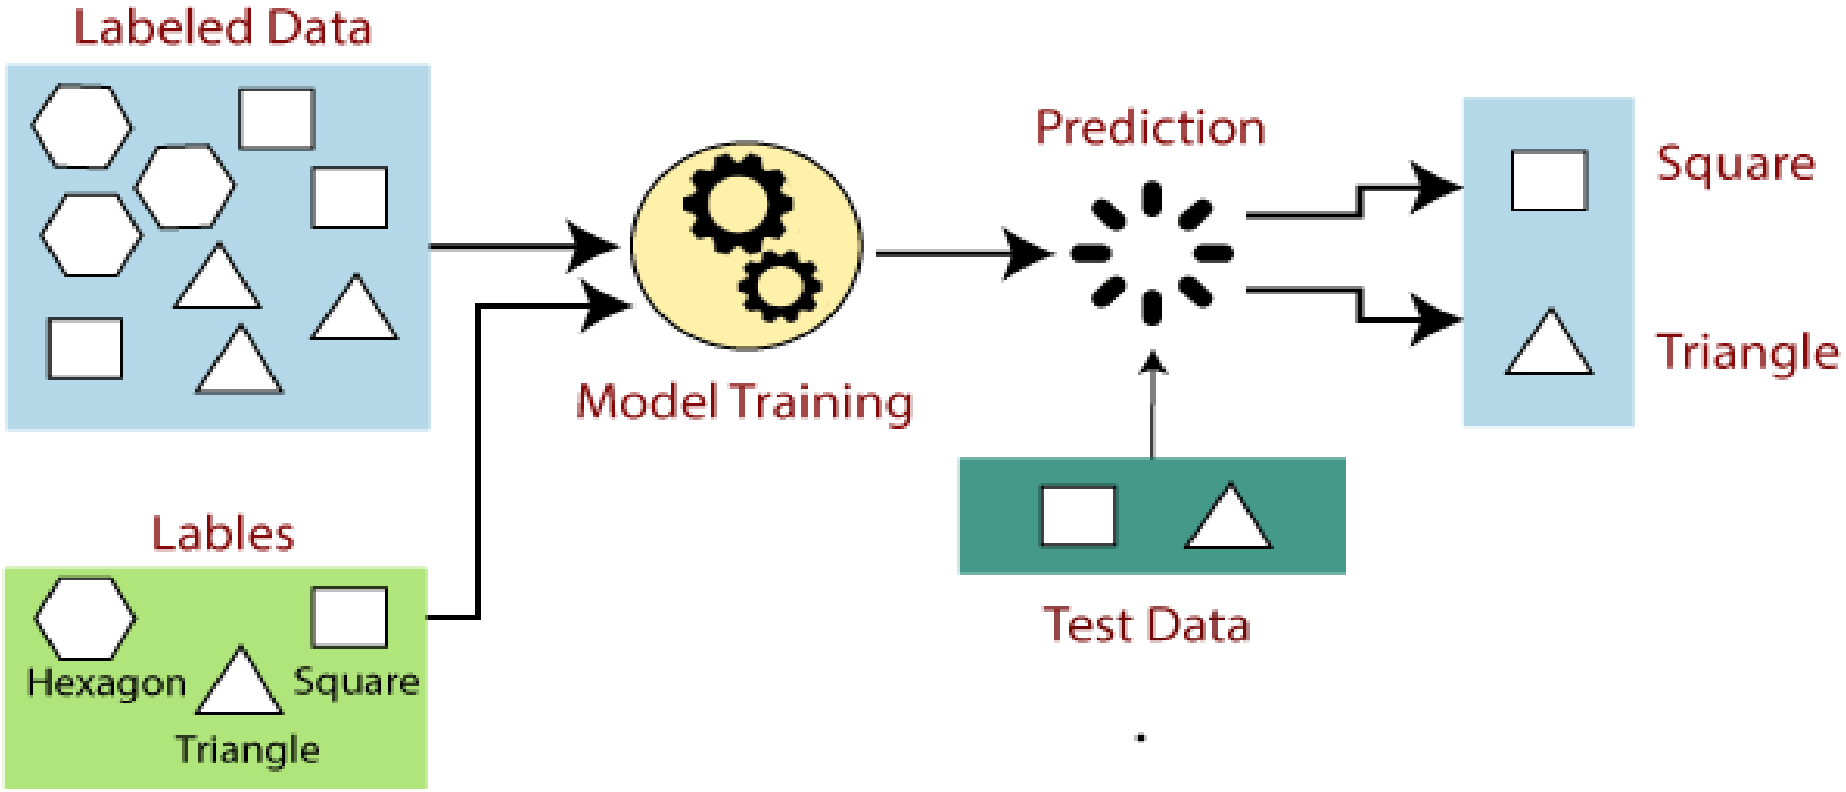

Machine Learning

*L'**apprendimento non supervisionato** è una tecnica di apprendimento automatico che consiste nel fornire al sistema informatico una serie di input (esperienza del sistema) che egli riclassificherà ed organizzerà sulla base di caratteristiche comuni per cercare di effettuare ragionamenti e previsioni sugli input successivi.*

*Al contrario dell'apprendimento supervisionato, durante l'apprendimento vengono forniti all'apprendista solo esempi **non annotati**, in quanto le classi non sono note a priori ma devono essere apprese automaticamente.*[1]

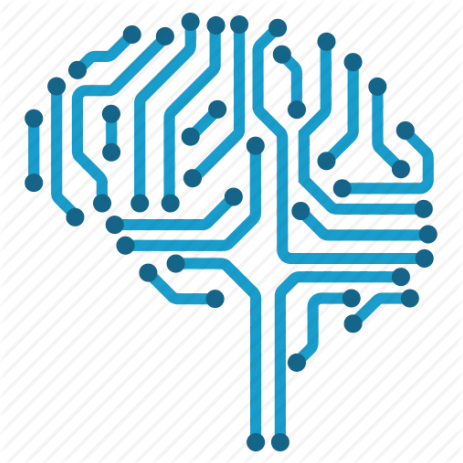

- insieme di dati di analisi (**data set**)
- **clustering** (raggruppamento)

1) https://it.wikipedia.org/wiki/Apprendimento_non_supervisionato

Machine Learning

Un esempio di **apprendimento non supervisionato**

- dati raw, no labels => il modello può raggruppare gli items per similitudine

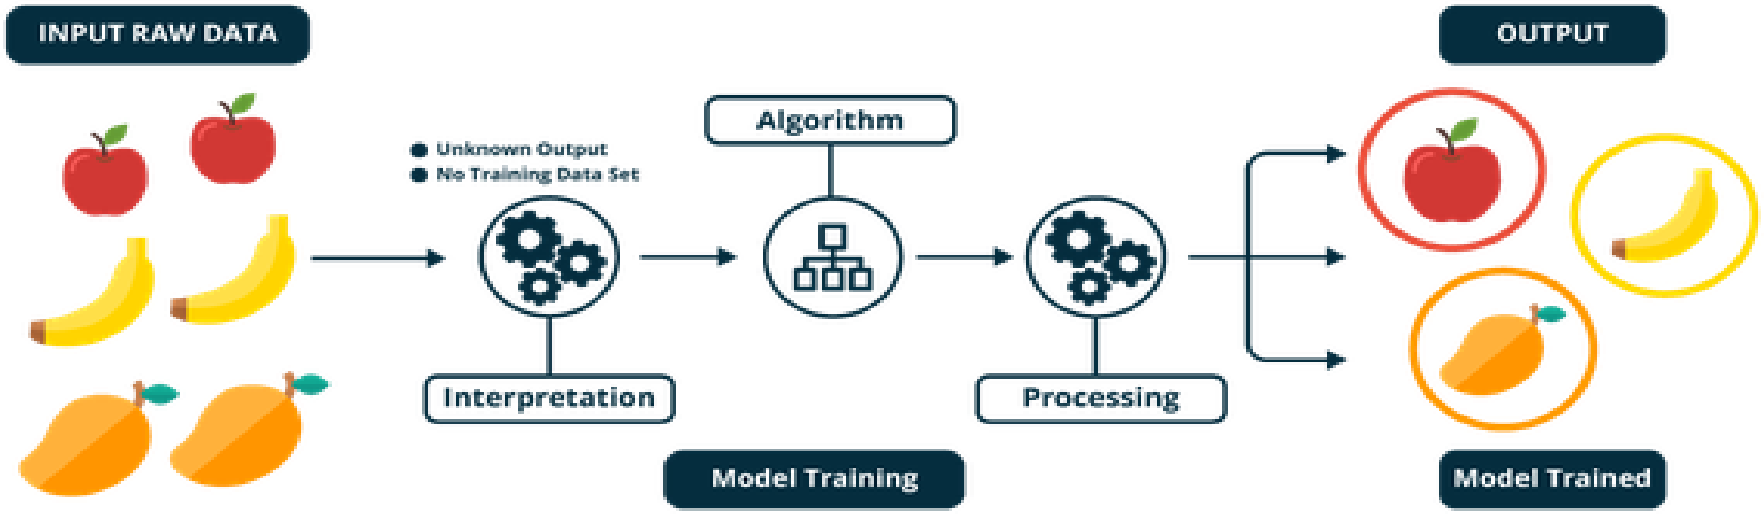

Machine Learning

*L'**apprendimento semi-supervisionato** è una tecnica di apprendimento automatico che combina una grande quantità di dati **non etichettati** con una piccola quantità di dati **etichettati**.*[1]

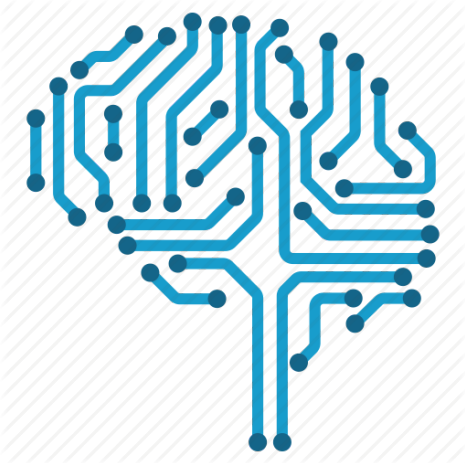

L'uso dell'apprendimento non supervisionato insieme a quello supervisionato permette all'algoritmo di clusterizzare gli esempi e poi di assegnare a **tutti gli elementi** di un certo gruppo, la **label** di quelli etichettati presenti nel gruppo

pros
- permette il labeling automatico di grandi quantità di dati altrimenti non etichettabili

cons
- i dati al confine fra due gruppi potrebbero avere etichette di entrambi
- introduce un po' di bias nel training

1) https://en.wikipedia.org/wiki/Semi-supervised_learning

Machine Learning

Un esempio di **apprendimento non supervisionato**

- dati raw, no labels => il modello può raggruppare gli items per similitudine

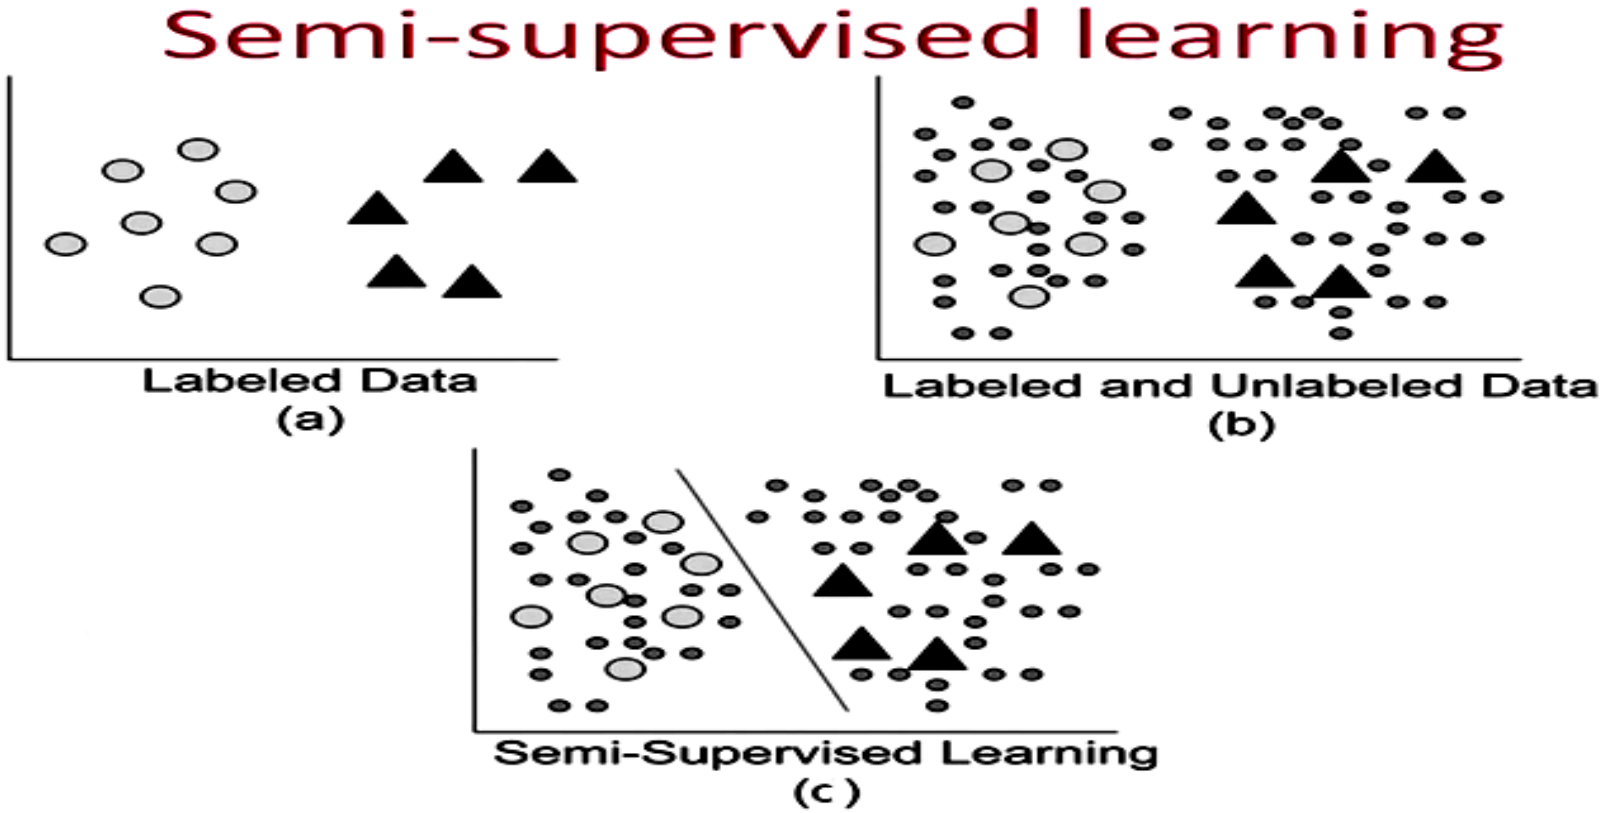

Machine Learning

Cos'è ML

- Vari tipi di Apprendimento automatico
  - Classificazione
  - Regressione
  - Clustering
- Tecniche
  - Alberi decisionali
  - Reti neurali
  - Tecniche statistiche
  - Regole di induzione

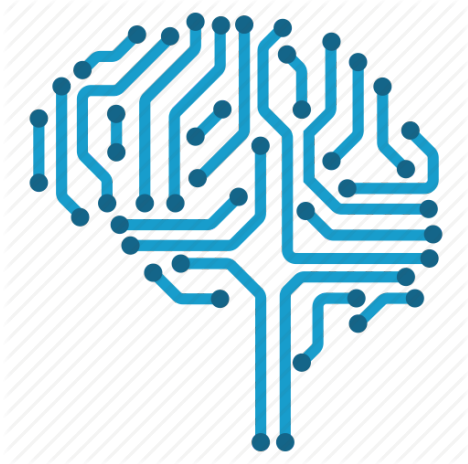

Machine Learning

Classificazione

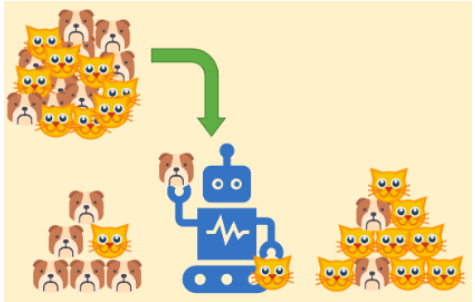

Nel machine learning, la **classificazione** è un concetto di **supervised learning** che sostanzialmente permette di **categorizzare** un insieme di dati in **classi**

I problemi più noti affrontabili con algoritmi di classificazione sono

- riconoscimento vocale
- riconoscimento facciale
- interpretazione della scrittura a mano
- classificazione dei documenti
- riconoscimento di immagini
- etc...

Esistono numerosi algoritmi di classificazione nella pratica del ML

Machine Learning

Regressione

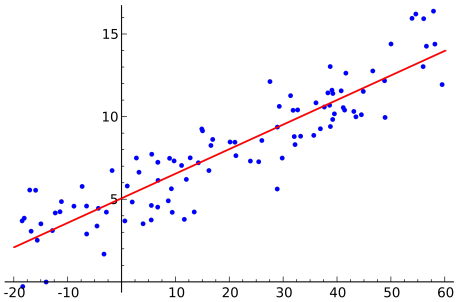

Nel machine learning, la **regressione** è un modello di calcolo **statistico** che, a differenza della classificazione, non assegna una classe ad ogni item esaminato ma assegna un **valore reale** stimato
E' quindi possibile, e quasi sempre vero, che items diversi vengano associati a valori reali diversi.

Il calcolo statistico è tipicamente il risultato di un algoritmo di **minimizzazione di errore**

la regressione fa sempre riferimento all'apprendimento **supervisionato**

I problemi più noti affrontabili con algoritmi di classificazione sono

- previsioni temperature meteo
- previsioni andamento azioni di borsa
- stima della capacità di spesa di clienti
- etc...

Esistono numerosi algoritmi di classificazione nella pratica del ML

Machine Learning

Clustering

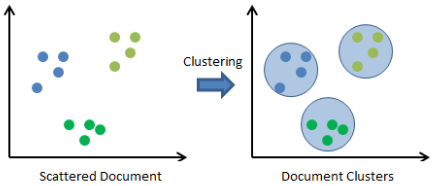

Nel machine learning, il **clustering** è un modello di calcolo che ha lo scopo di **raggruppare** gli items analizzati in gruppi con caratteristiche simili.
Il calcolo effettuato per determinare le similitudini fra items è spesso la **distanza** in qualche spazio n-dimensionale
Il modo con il quale è calcolata tale distanza va sotto il nome di **metrica**
La scelta della metrica influenza fortemente il risultato della cluterizzazione

Il clustering fa riferimento ad analisi di apprendimento **non supervisionato**

E' di supporto in algoritmi **semi-supervised**

Machine Learning

Tecniche per la classificazione

- Alberi decisionali
- Reti neurali
- Tecniche statistiche
- Regole di induzione

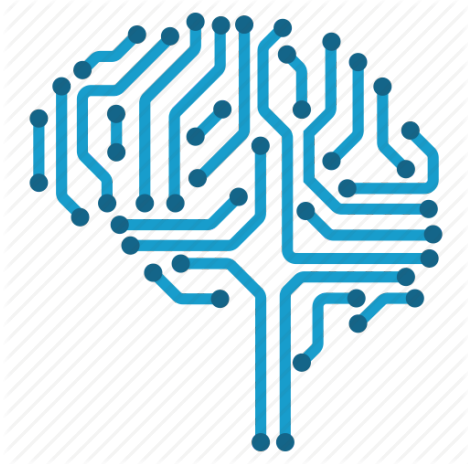

Machine Learning

I cinque passi della scienza dei dati

- **Porre una domanda interessante**
- **Ottenere i dati**
- **Esplorare i dati**
- **Creare un modello per i dati**
- **Comunicare e presentare i risultati**

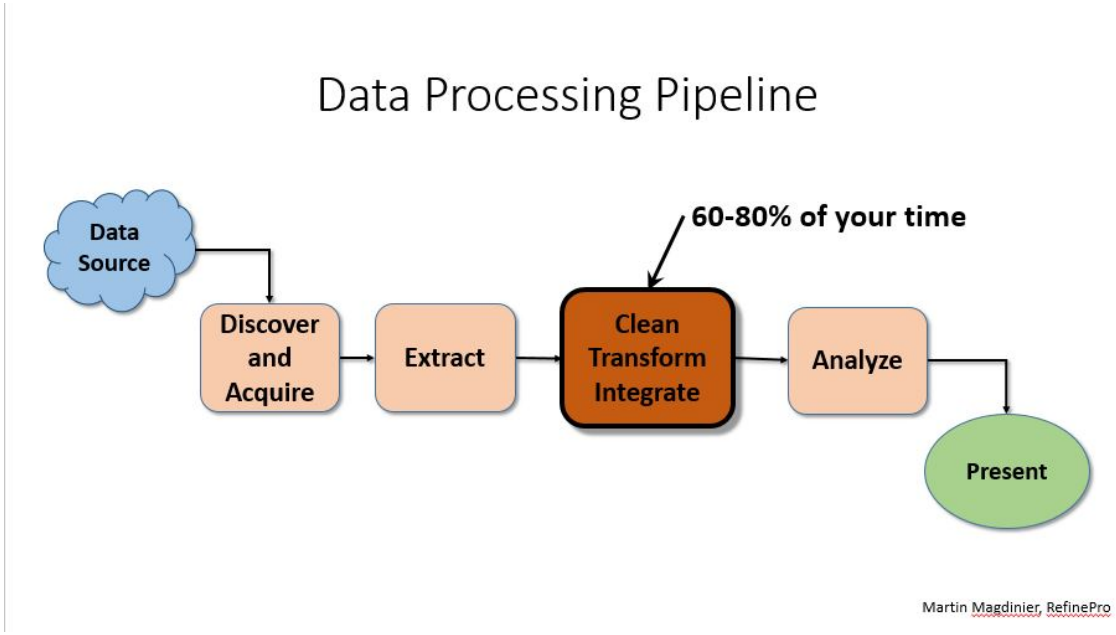

Machine Learning

Strumenti software

Linguaggio di riferimento : **Python3.x**

Librerie Python :

- Scikit-learn
- Pandas
- Numpy
- Matplotlib

Jupyter Notebook

Machine Learning

l' **Hello world!** del ML

Problema di classificazione

- **apprendimento supervisionato**

Iris Data Set

Iris Versicolor **Iris Setosa** **Iris Virginica**

```
Petal length,Petal width,Class
1.4,0.2,Iris-setosa
1.4,0.2,Iris-setosa
...
5.0,1.7,Iris-versicolor
4.5,1.5,Iris-versicolor
...
5.4,2.3,Iris-virginica
5.1,1.8,Iris-virginica
```

Iris 2D - distribuzione

distribuzione degli items come punti su un piano

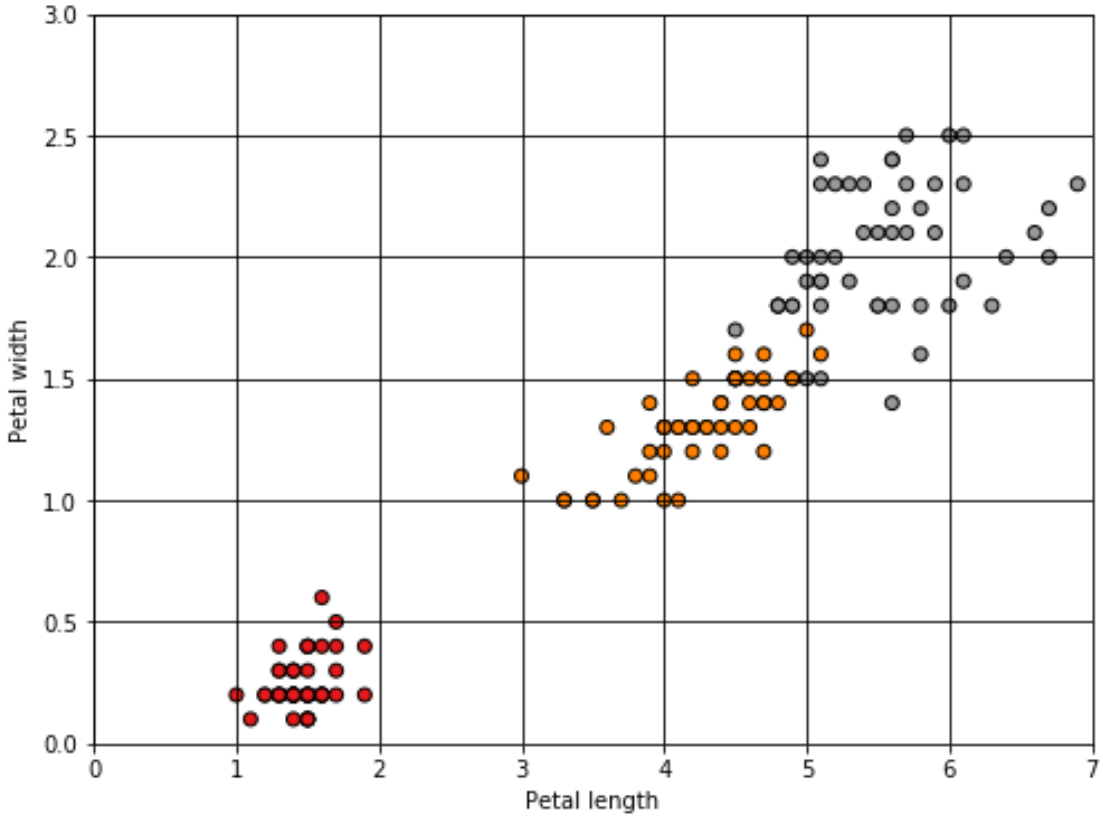

Iris-setosa Iris-versicolor Iris-virginica

Iris 2D - Addestramento

formalismo standard

Si indica con **X** l'insieme dei valori delle colonne delle features Si indica con **y** la colonna delle classi

PYTHON

```
# importo il modulo tree da sklearn (scikit-learn) libreria per ML
from sklearn import tree
# fra gli alberi scelgo un albero di decisione
clf = tree.DecisionTreeClassifier()
# l'operazione di fit addestra il classificatore coi dati presenti in X e y
clf = clf.fit(X, y)
```

Iris 2D - Albero decisionale

Cosa costruisce l'operazione di **fit** di un **DecisionTreeClassifier**

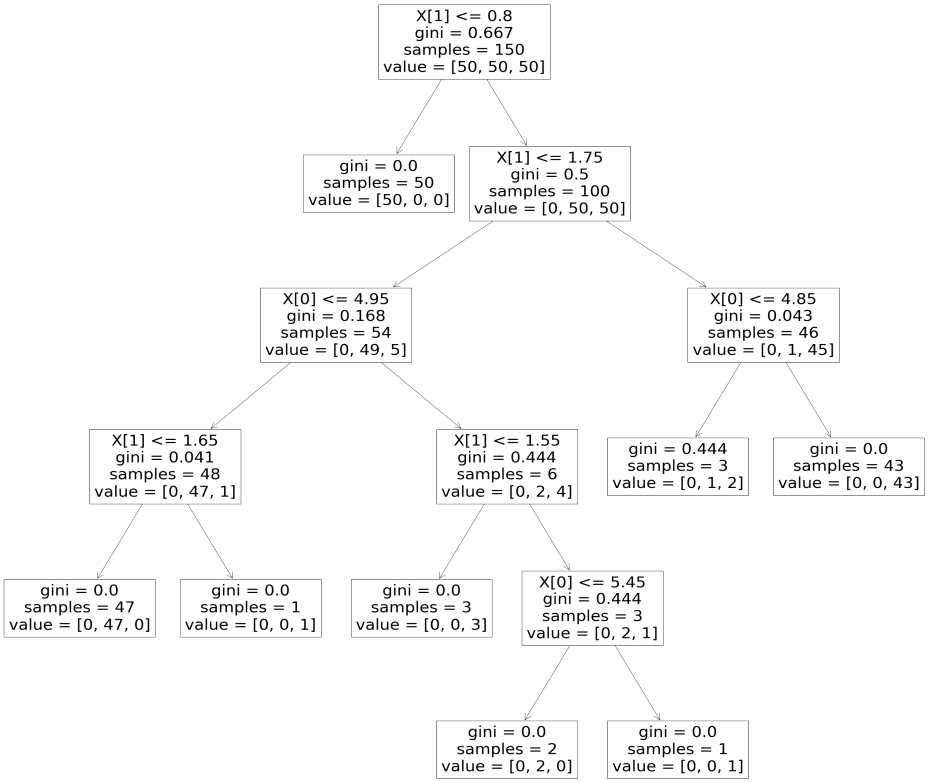

apri

Iris 2D - Albero decisionale (testo)

```
|--- petal_width <= 0.80',
| |--- class: 0',
|--- petal_width > 0.80',
| |--- petal_width <= 1.75',
| | |--- petal_length <= 4.95',
| | | |--- petal_width <= 1.65',
| | | | |--- class: 1',
| | | |--- petal_width > 1.65',
| | | | |--- class: 2',
| | |--- petal_length > 4.95',
| | | |--- petal_width <= 1.55',
| | | | |--- class: 2',
| | | |--- petal_width > 1.55',
| | | | |--- petal_length <= 5.45',
| | | | | |--- class: 1',
| | | | |--- petal_length > 5.45',
| | | | | |--- class: 2',
| |--- petal_width > 1.75',
| | |--- petal_length <= 4.85',
| | | |--- class: 2',
| | |--- petal_length > 4.85',
| | | |--- class: 2',
```

Iris 2D - Albero decisionale (grafica)

tagli decisionali dell'algoritmo J48

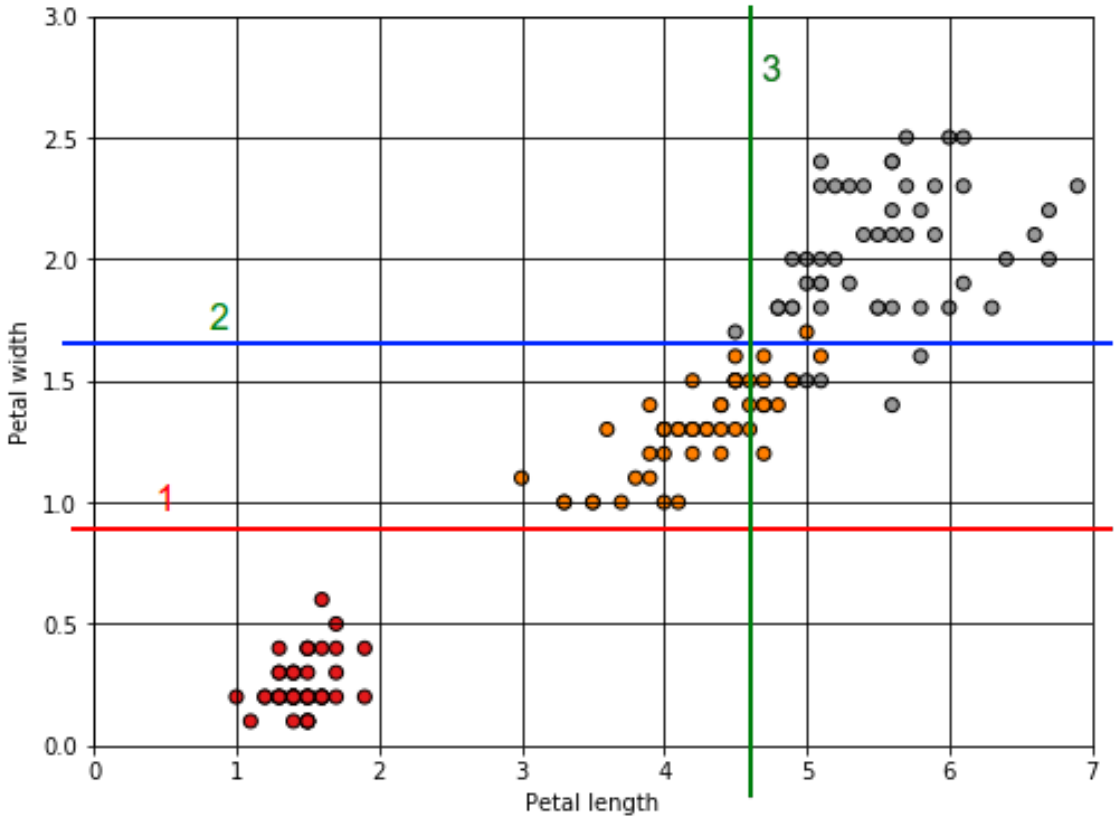

Iris 2D - predizione

- prendiamo altri items
- per esempio: (4, 1.5) e (5, 1.6)
- dove si posizionano?

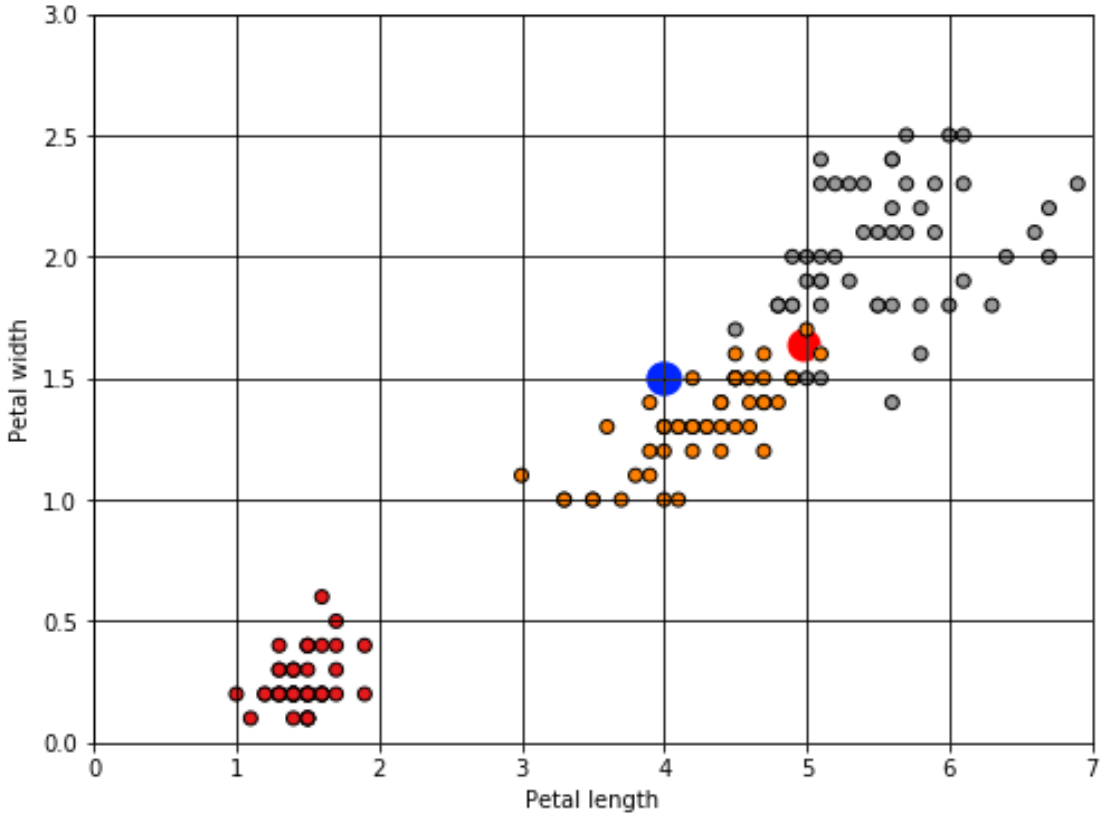

Iris 2D - predizione

- usiamo sklearn

```python
clf.predict([[4, 1.5]])
```

PYTHON

```
array([1])
```

OUTPUT

- Predizione sulla classe 2 (Iris-versicolor)

```python
clf.predict([[5, 1.6]])
clf.predict_proba([[5, 1.6]])
```

PYTHON

```
array([1]) # classe 2
array([[ 0.,  1.,  0.]]) # 100% confidenza
```

OUTPUT

Iris 2D - predizione

- un esempio più distante dal dataset (outlier)

PYTHON

```
clf.predict([[2, 2]])
clf.predict_proba([[2, 2]])
```

OUTPUT

```
array([2]) # classe 2
array([[ 0,  0.33333333, 0.66666667]]) # 33% e 66% di confidenza
```

Iris 2D - SVM

PYTHON

```python
# cambiamo classificatore
# Support Vector Machine
from sklearn.svm import SVC
clf = SVC(gamma='auto', probability=True)
clf.fit(X, y)
print(clf.predict([[4, 1.5]]))
print(clf.predict_proba([[4, 1.5]]))
```

OUTPUT

```
array([1])
array([[ 0.00839442,  0.97857937,  0.01302621]])
```

- la **confidence** è spalmata sulle tre classi
- confidence = livello di affidabilità della predizione
- valore reale in [0,1]

Iris 2D - Valutazione del classificatore

Le modalità di valutazione sono diverse a seconda del tipo di algoritmo

i modelli di classificazione
i modelli di regressione
i modelli di clustering

[cit. slides Mordonini]

- Dataset Split
- Cross Validation

Iris 2D - Valutazione del classificatore

Dataset Split

- tipicamente
  - 66% train dataset
  - 33% test dataset
- nel nostro caso: 150 elementi
  - 100 training
  - 50 test
- **classi bilanciate**

Iris 2D - Valutazione del classificatore

- Dividiamo il dataset (X,y) in [(X_train, y_train) e (X_test, y_test)]

PYTHON

```python
from sklearn.model_selection import train_test_split
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.33, random_state=42)
print(len(X_train), len(y_train))
print(len(X_test), len(y_test))
```

OUTPUT

```
100 100
50 50
```

- addestriamo sul **solo** training set

PYTHON

```python
clf.fit(X_train, y_train)
```

NOTA: random_state: inizializza il seed del generatore random

Iris 2D - Valutazione del classificatore

- Testiamo il classificatore addestrato sul **solo** training set
- sia sullo stesso training set che sul test set

PYTHON

```
print("TRAIN SET", clf.score(X_train, y_train))
print("TEST  SET", clf.score(X_test, y_test))
```

OUTPUT

```
TRAIN SET 0.99  # errore di 1%
TEST  SET 0.98  # errore di 2%
```

Iris 2D - Valutazione del classificatore

- quali sono gli errori?
- concetto di **accuracy** - accuratezza della classificazione

PYTHON

```
print("Errori in training set")
predictions = clf.predict(X_train)
for elem, prediction, label in zip(X_train, predictions, y_train):
  if prediction != label:
    print(elem, 'has been classified as ', prediction, 'and should be ', label)
# similmente per test set...
```

OUTPUT

```
Errori in training set
[ 4.8  1.8] has been classified as  2 and should be  1

Errori in test set
[ 5.1  1.5] has been classified as  1 and should be  2
```

Iris 2D - Valutazione del classificatore

- Matrice di confusione
  - quanti elementi di una certa classe sono associati alle altre classi

PYTHON

```python
from sklearn.metrics import confusion_matrix
cm = confusion_matrix(y_train, clf.predict(X_train))
print("CM per Train set\n", cm)
# similmente per test set...
```

OUTPUT

```
CM per Train set
[[31  0  0]
 [ 0 34  1]
 [ 0  0 34]]


CM per Test set
[[19  0  0]
[  0 15  0]
[  0  1 15]]
```

Iris 2D - Valutazione del classificatore

Cross Validation

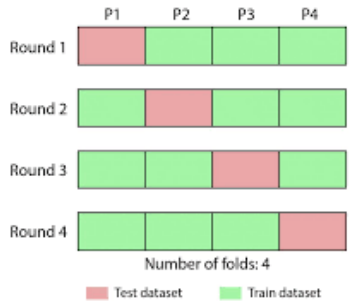

- Quando? Se abbiamo pochi dati e non possiamo permetterci di splittare fra train e test set
- parametri
    - folds (numero di blocchi in cui suddivido il mio dataset)

PYTHON

```
from sklearn.model_selection import cross_val_score
print(cross_val_score(clf, X, y, cv=4))
```

OUTPUT

```
[ 0.97435897  0.94871795  0.91666667  0.97222222]
```

- media di accuracy: **0.95**

Iris 2D - Valutazione del classificatore

- si lascia per esercizio al lettore
  - addestramento di due classificatore SVM e RF (Random Forest)
  - valutazione dell'accuratezza con CV
  - valutazione dell'accuratezza con Dataset Split
  - visualizzazione matrici di confusione
  - confronto prestazioni fra SVM e RF

Giulio Angiani
Universita' degli Studi di Parma